ARTFACT

VERIFICADOR DE ARTIGOS CIENTÍFICOS

Brasília/DF

2026

Integrantes do Grupo 08

João Vitor Carvalho Barbosa

Keila Alves Ferreira

Ketlyn Karen Silva de Morais

Thayná Gonçalves Dutra

Victor Barbosa da Silva

Vinícius César Sena Torres

SUMÁRIO

1.INTRODUÇÃO 4

2.PROCESSO DE PREPARAÇÃO DOS DADOS E TREINAMENTO DO MODELO 5

3.CRITÉRIOS UTILIZADOS PARA A SELEÇÃO DA ABORDAGEM ADOTADA 6

4.MÉTRICAS DE DESEMPENHO E ANÁLISE DOS RESULTADOS 6

5.PRINCIPAIS DESAFIOS 7

6.APRENDIZADOS E LIÇÕES 7

1. INTRODUÇÃO

Este relatório descreve os processos e decisões arquitetônicas tomadas para o Produto Mínimo Viável (MVP) focado na base de dados biomédica PubMed. O projeto opera primariamente como um sistema avançado de RAG (Retrieval-Augmented Generation) para validação de fatos baseada em evidência científica primária.

2. PROCESSO DE PREPARAÇÃO DOS DADOS E TREINAMENTO DO MODELO

2.1 Preparação de Dados (Ingestão e Recuperação)

2.1.1 Extração na Fonte

O código realiza consultas orquestradas (src/fatofake/pubmed.py) à API do NCBI (PubMed E-utilities). Devido ao escopo de MVP focado apenas no PubMed, captura-se os metadados e resumos (abstracts) originais em inglês de forma determinística, abstraindo a complexidade de PDFs e artigos completos de texto aberto (PMC).

2.1.2 Processamento (Chunking)

O texto recuperado dos abstracts científicos passa por um processo de segmentação (chunking.py), transformando estruturas monolíticas em pedaços granulares (EvidenceChunk).

2.1.3 Vetorização e Indexação

Utiliza-se um encoder semântico pré-treinado de contexto multilíngue (sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2). Ele converte cada chunk para um vetor denso no espaço latente. Esses dados são persistidos no banco de dados vetorial Qdrant (src/fatofake/qdrant_retrieval.py).

2.2 Treinamento (Engenharia do Modelo LLM)

O modelo responsável pela inteligência final é alimentado via integração com a API Gemini (src/fatofake/gemini_evidence.py).

O processo de adequação da IA às necessidades da verificação de fatos é realizado por meio da definição rigorosa da estrutura de saída, contemplando:

- Utilização de geração forçada de JSON Schema;
- Extração de variáveis epidemiológicas PICO;
- Aplicação de metodologias de avaliação clínica consolidadas, como ROB2, ROBINS-I e AMSTAR2;
- Exigência de evidências textuais literais obtidas diretamente das fontes científicas.

3. CRITÉRIOS UTILIZADOS PARA A SELEÇÃO DA ABORDAGEM ADOTADA

As decisões de engenharia encontradas na branch validam critérios rigorosos contra alucinações da IA e em prol da precisão científica.

3.1 Abordagem PubMed-Only no MVP

Optou-se por focar exclusivamente na extração dos abstracts via PubMed para este MVP. Essa abordagem assegura acesso rápido a uma biblioteca vasta com dados concisos, estruturados e metodológicos, reduzindo ruídos contextuais durante a extração de informações.

3.2 Recuperação Híbrida (Hybrid Retrieval)

O sistema adota uma abordagem híbrida de busca, composta por:

a) Índice Lexical (BM25)

Excelente para identificação de termos médicos, palavras-chave e identificadores específicos.

b) Índice Semântico (Embeddings Densos)

Permite associar consultas em português a conteúdos científicos disponíveis em inglês sem depender exclusivamente de tradução literal.

c) Reciprocal Rank Fusion (RRF)

Mecanismo utilizado para combinar os resultados dos índices lexical e semântico, equilibrando o ranqueamento de documentos retornados.

3.3 Extração Fact-Based

Em vez de apresentar apenas uma classificação binária entre verdadeiro ou falso, a plataforma estrutura uma tabela de evidências baseada em componentes PICO, classificando os resultados em:

- SUPPORTS;
- CONTRADICTS;
- NEUTRAL;
- UNCERTAIN.

4. MÉTRICAS DE DESEMPENHO E ANÁLISE DOS RESULTADOS

A estratégia de validação do projeto apoia-se em avaliações contínuas e offline, medindo a qualidade dos mecanismos de recuperação sem depender continuamente de consultas pagas aos modelos de linguagem.

4.1 Métricas de Recuperação da Informação

As métricas avaliadas incluem:

- Precision@K;
- Recall@K;
- Mean Reciprocal Rank (MRR);
- Normalized Discounted Cumulative Gain (NDCG@K);
- Taxa de Abstenção do Recuperador.

4.2 Métricas de Ancoragem

Para garantir que o modelo não gere evidências inexistentes, foram analisados:

- Citation Validity;
- Taxa de Abstenção do LLM;
- Structural Groundedness.

4.3 Análise dos Resultados

Os experimentos demonstraram que a busca vetorial semântica apresenta efetividade na associação entre alegações em português e evidências científicas em inglês.

A utilização da recuperação híbrida elevou a acurácia geral do sistema, melhorando simultaneamente métricas de precisão, revocação e posicionamento das evidências.

5.PRINCIPAIS DESAFIOS

Os principais desafios foram lidar com diferentes formatos de entrada, recuperar textos completos de fontes externas, respeitar limites das APIs científicas e manter a rastreabilidade dos resultados gerados pela IA.

Também foi necessário tratar falhas de rede, artigos sem texto completo, respostas incompletas, estudos duplicados e resultados conflitantes. Para reduzir interpretações incorretas, o sistema passou a exibir os trechos originais, os links das fontes e as limitações da análise.

O backend recebeu melhorias na organização do fluxo de análise, separando a leitura do artigo, a seleção das alegações, a busca de evidências e a apresentação dos resultados.

6.APRENDIZADOS E LIÇÕES

O desenvolvimento do projeto proporcionou importantes aprendizados nas áreas de inteligência artificial, análise de dados científicos, integração de APIs e desenvolvimento de sistemas voltados para apoio à tomada de decisão.

Ao longo da construção da plataforma, os integrantes aprofundaram seus conhecimentos sobre processamento de linguagem natural, recuperação semântica de informações, classificação de evidências e utilização de bases científicas como PubMed.

Além do aprendizado técnico, o projeto destacou a importância do trabalho colaborativo e da adaptação diante dos desafios encontrados. A equipe compreendeu que a qualidade das informações depende não apenas da tecnologia utilizada, mas também da transparência do processo de análise e da correta interpretação dos resultados.

Como principal lição, observou-se que a inteligência artificial pode atuar como uma ferramenta de apoio extremamente valiosa na verificação científica. Contudo, a

validação humana permanece indispensável para garantir a confiabilidade das conclusões produzidas.