Análise Exploratória de Dados — Corpus PubMed

RES IA ELD UnB — Turma 1 | Grupo 08

Victor Barbosa da Silva • Keila Alves Ferreira • Thayná Gonçalves Dutra
João Vitor Carvalho Barbosa • Vinícius César Sena Torres • Ketlyn Karen Silva de Morais

Contextualização do tema

Esta análise utiliza como estudo de caso a possível associação entre o consumo de café e o risco de câncer de próstata. O tema foi escolhido porque representa bem o tipo de alegação de saúde que costuma circular em notícias e redes sociais de maneira simplificada, muitas vezes transformando uma associação estatística em uma afirmação de causa e efeito.

A literatura científica sobre o assunto reúne estudos observacionais, revisões sistemáticas e meta-análises com diferentes populações, níveis de consumo e resultados. Essa diversidade torna o tema adequado para validar a aplicação Fato ou Fake, pois exige buscar múltiplas fontes, avaliar a qualidade metodológica dos estudos e identificar evidências favoráveis, contrárias ou inconclusivas.

O objetivo do projeto não é afirmar previamente que o café causa ou previne o câncer de próstata. A associação funciona como um caso prático para demonstrar como a aplicação pode organizar evidências científicas, destacar limitações e apresentar uma resposta explicável, preservando o senso crítico do usuário.

Resumo executivo

Foram analisados 100 dos 116 registros retornados pelo PubMed (86.2% de cobertura). Não há PMIDs nem títulos normalizados duplicados, todos os registros possuem ano e URL, 93% possuem DOI, e 2 não informam autores.

A amostra cobre os períodos de 1964 a 2026. Somente 39 títulos mencionam simultaneamente café e próstata, enquanto 12 não mencionam nenhum dos conceitos. Isso não comprova irrelevância, mas mostra a necessidade de filtrar o corpus antes do RAG.

1. Contexto e métodos

1.1 Objetivo

Compreender o conjunto de artigos científicos que alimentará o MVP Fato ou Fake, avaliando cobertura, qualidade dos metadados, distribuição temporal, concentração por periódico e características textuais dos títulos.

1.2 Unidade de análise e fonte

- Grão: um registro bibliográfico por PMID.
- Fonte oficial: PubMed, por meio das E-utilities do NCBI.
- Consulta: ("Coffee"[MeSH Terms] OR coffee[Title/Abstract]) AND ("Prostatic Neoplasms"[MeSH Terms] OR "prostate cancer"[Title/Abstract])
- Amostra: até 100 registros ordenados por relevância pelo PubMed.
- Data da coleta: 2026-09-28T11:45:37.295122+00:00.
- Snapshot: data/pubmed_cafe_cancer_prostata.csv.

1.3 Premissas e limitações

- A amostra por relevância não representa todo o PubMed nem permite inferências epidemiológicas.
- Ausência de DOI pode ser legítima e não significa necessariamente erro.
- A análise textual usa títulos; não substitui a leitura de resumos ou textos completos.
- Frequência de termos indica temas recorrentes, não apoio ou contradição da alegação.
- A consulta e o ranking podem mudar; o snapshot preserva esta execução.

2. Visão geral e qualidade dos dados

Indicador	Resultado
Registros analisados	100
Colunas	9
Cobertura da consulta	86.2%
PMIDs duplicados	0
Títulos normalizados duplicados	0
Registros sem DOI	7 (7.0%)
Registros sem autores	2 (2.0%)
Período observado	1964–2026

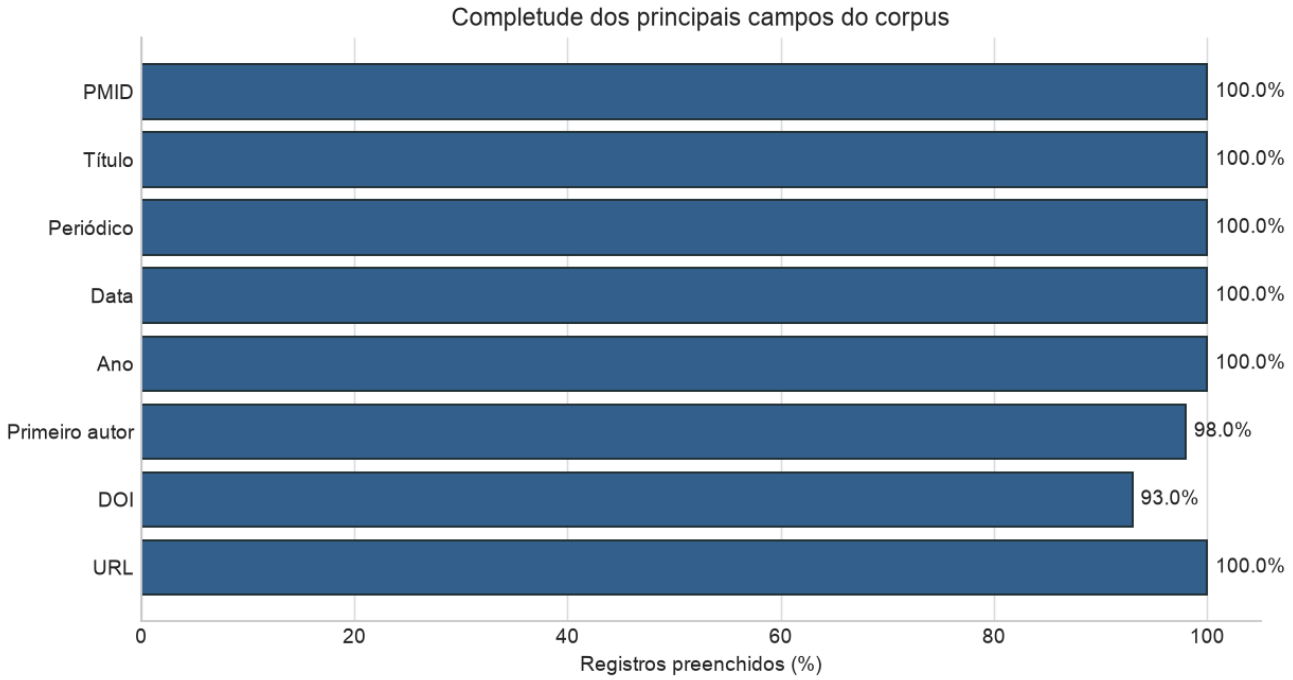


Figura 1 — Completude dos principais campos do corpus.

PMID, título, periódico, data, ano e URL estão completos. DOI apresenta 93% de completude; a ausência limita cruzamentos entre bases, mas não invalida o registro PubMed.

3. Dicionário de dados

Campo	Tipo	Definição	Formato	Ausentes	Observação
pmid	Texto	Identificador único no PubMed.	Dígitos	0	Chave candidata; obrigatório.
title	Texto	Título da publicação.	Texto livre	0	Usado na EDA textual.
journal	Texto	Periódico informado.	Texto livre	0	Completo nesta amostra.
publication_date	Texto	Data original do PubMed.	Formato variável	0	Origem da coluna year.
year	Inteiro	Ano extraído da data.	AAAA	0	Entre 1800 e o ano da coleta.
author_count	Inteiro	Número de autores retornados.	Contagem	2*	Zero representa autoria ausente.
first_author	Texto	Primeiro autor retornado.	Sobrenome/iniciais	2	Ausente quando author_count é zero.
doi	Texto	Digital Object Identifier.	10.xxxx/...	7	Opcional; útil para interoperabilidade.

url	Texto	Link canônico do PubMed.	HTTPS	0	Domínio validado.

* Em author_count, dois valores zero representam ausência de metadados de autoria.

4. Triagem temática aproximada

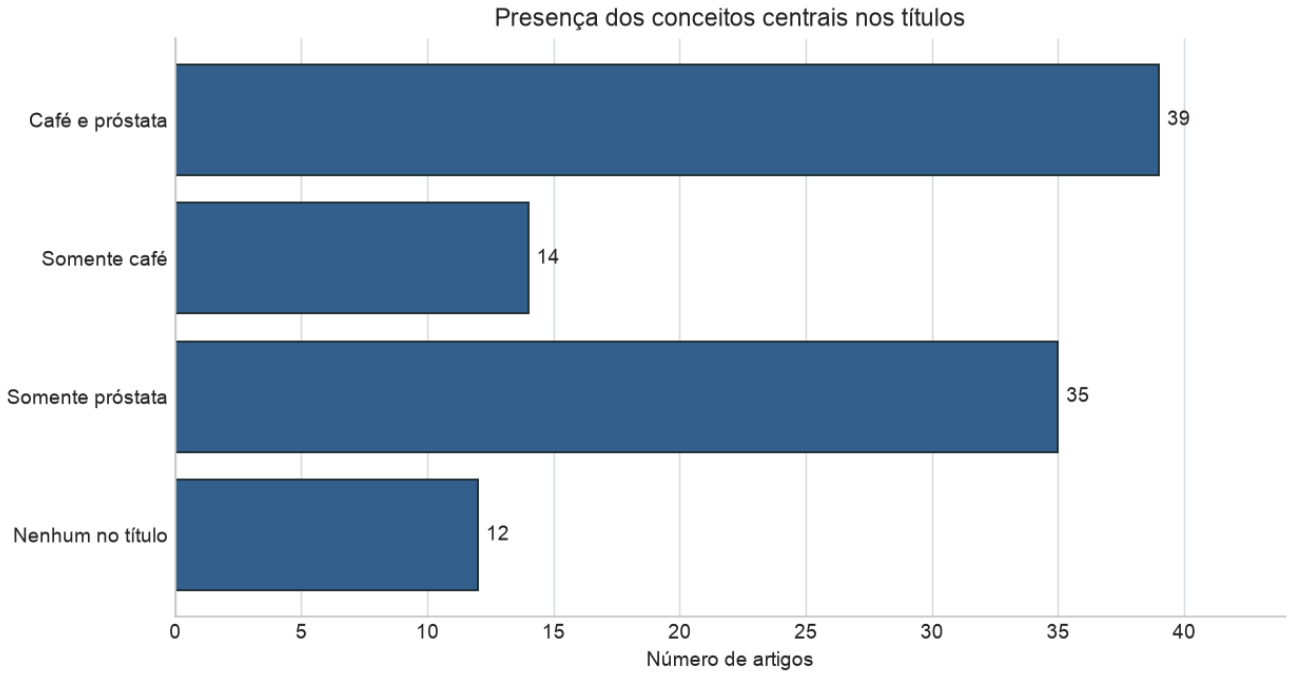


Figura 2 — Presença dos conceitos centrais nos títulos.

39 títulos mencionam ambos os conceitos; 12 não mencionam nenhum. Como a consulta também considera resumo e MeSH, esse resultado é um sinal de triagem, não uma prova de irrelevância.

5. Distribuição temporal

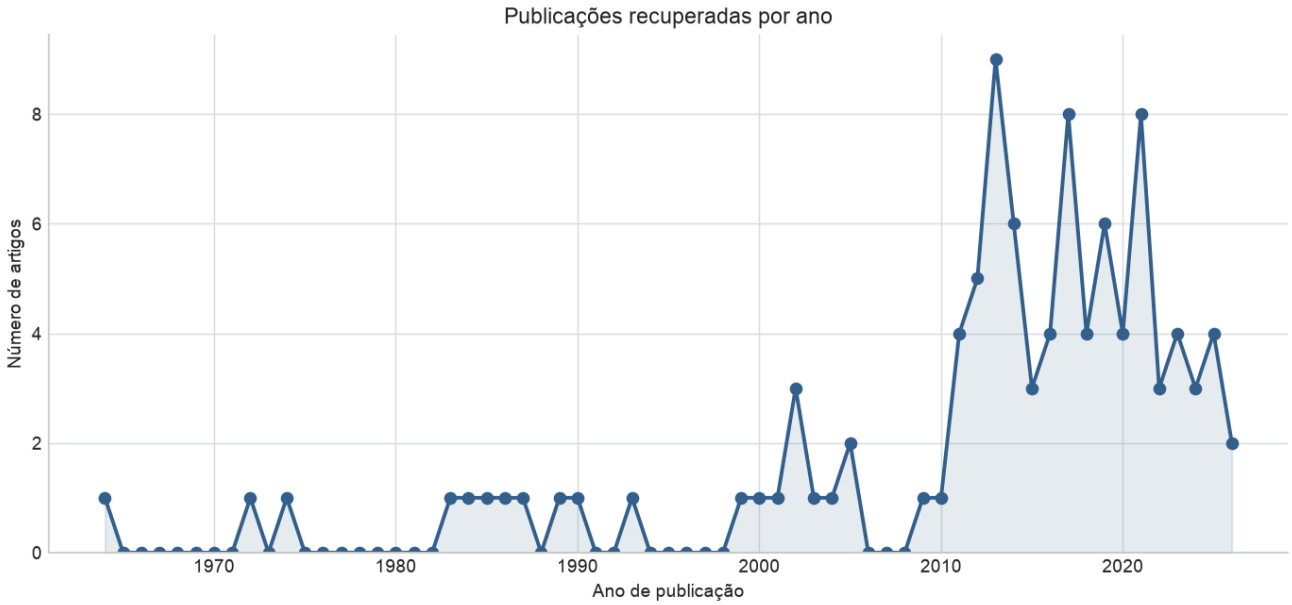


Figura 3 — Publicações recuperadas por ano.

A amostra se estende de 1964 a 2026; 2013 concentra o maior número de registros (9). Anos sem registros são representados por zero.

6. Concentração por periódico

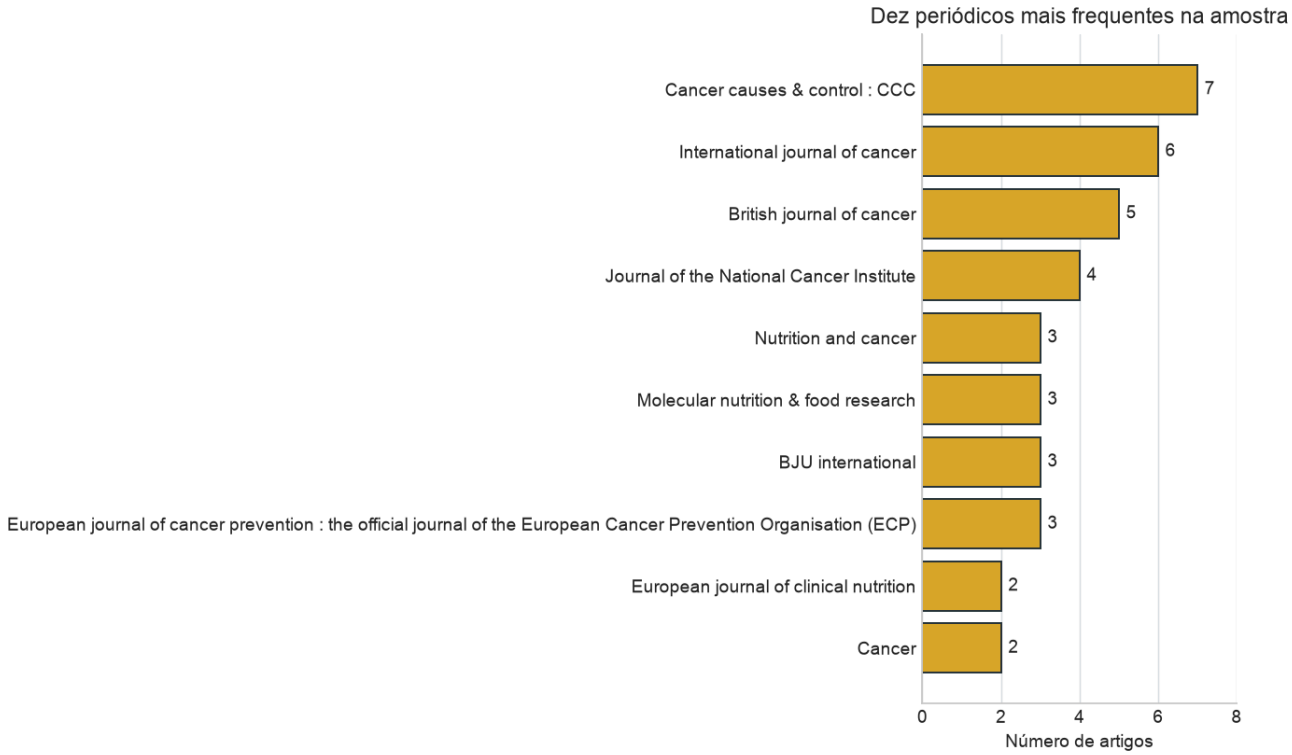


Figura 4 — Dez periódicos mais frequentes.

Os dez periódicos mais frequentes concentram 38% da amostra, indicando que os registros estão distribuídos entre muitas fontes editoriais.

7. Características textuais

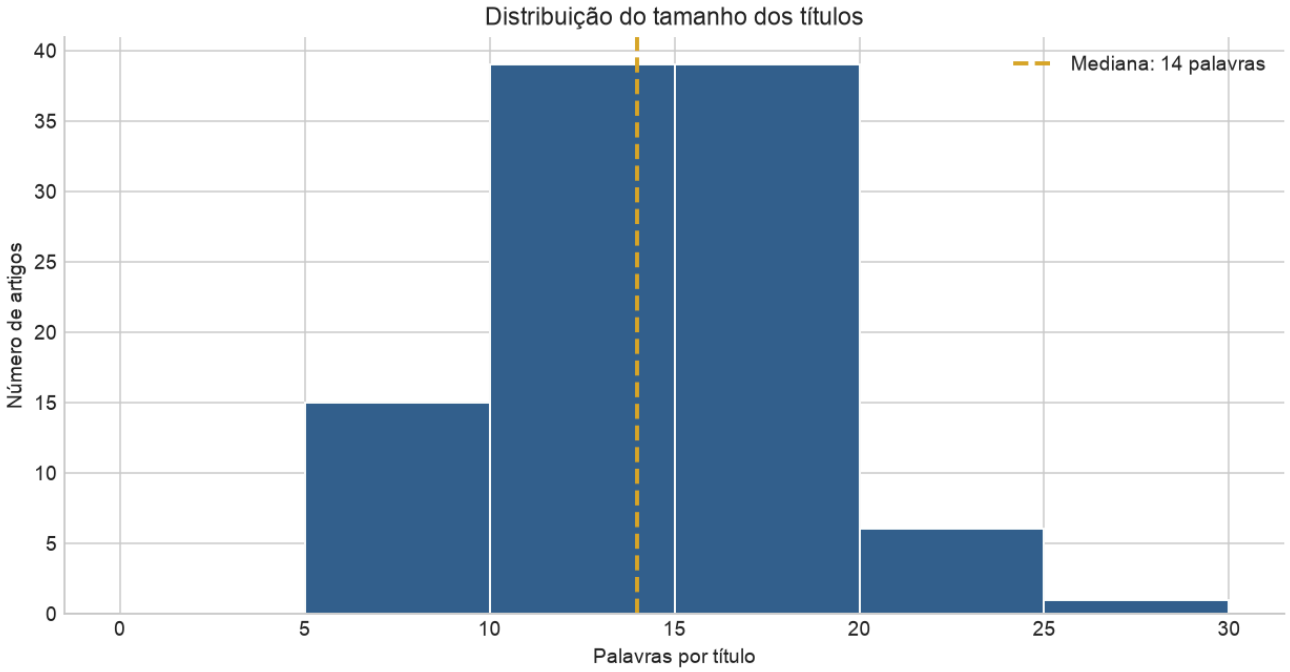


Figura 5 — Distribuição do tamanho dos títulos.

Os títulos possuem mediana de 14 palavras e IQR de 6 palavras.

8. Medidas de dispersão

Variável	n	Média	Mediana	DP	Variância	Mín.	Q1	Q3	Máx.	Amplitude	IQR	CV
Ano de publicação	100	2012.15	2015.50	12.44	154.73	1964	2011	2020	2026	62	9	—
Número de autores	98	7.08	6	6.37	40.53	1	3	9	47	46	6	89.9%
Palavras no título	100	14.10	14	4.27	18.27	5	11	17	28	23	6	30.3%
Artigos por ano	63	1.59	1	2.22	4.92	0	0	2.50	9	9	2.50	139.8%

- Títulos: IQR de 6 palavras, indicando concentração moderada em torno da mediana de 14.
- Autores: desvio-padrão de 6,37 e máximo de 47; poucos artigos com muitos autores ampliam a dispersão.
- Artigos por ano: CV de 139,8%, coerente com muitos anos de volume baixo ou zero na amostra.

9. Termos mais frequentes

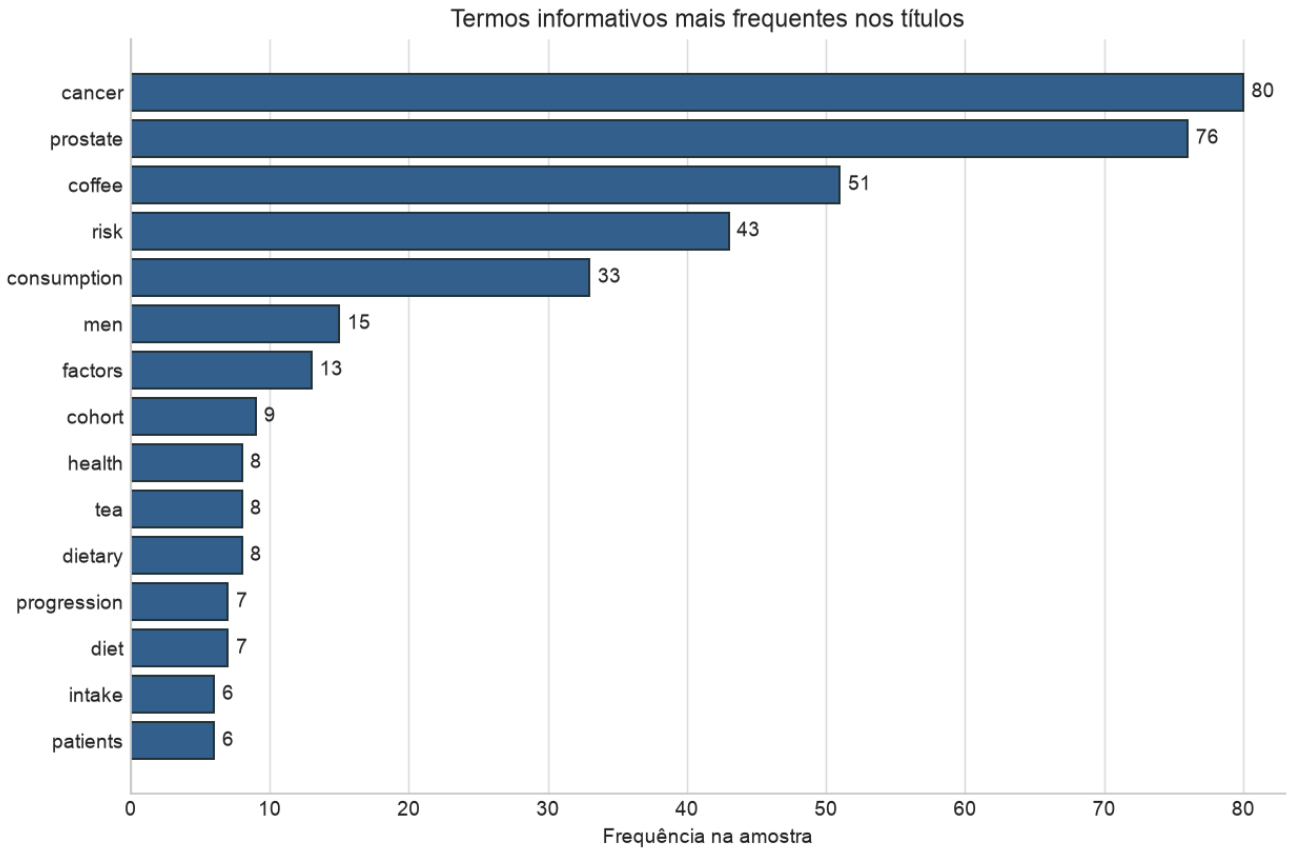


Figura 6 — Termos informativos mais frequentes nos títulos.

Cancer, prostate, coffee, risk e consumption predominam, coerentes com a consulta. Frequência lexical não indica causalidade nem direção da evidência.

Considerações finais

A análise exploratória permitiu compreender a estrutura, a qualidade e as principais características do conjunto de artigos recuperados no PubMed sobre a possível associação entre o consumo de café e o câncer de próstata. O dataset apresentou boa integridade estrutural, sem registros duplicados e com alta completude dos principais metadados, embora alguns artigos não possuam DOI ou informações de autoria.

Os resultados também demonstraram que a busca recupera publicações de diferentes períodos e periódicos, mas nem todos os títulos mencionam simultaneamente os dois conceitos pesquisados. Isso reforça a necessidade de aplicar filtros de relevância, análise dos resumos e recuperação híbrida antes que os artigos sejam utilizados pelo sistema.

Conclui-se que o conjunto de dados é adequado como fonte documental para o pipeline de recuperação de evidências do Fato ou Fake. Entretanto, ele não possui rótulos de veracidade, apoio ou contradição e, portanto, não deve ser utilizado isoladamente para treinar ou avaliar um classificador de fake news. As próximas etapas deverão ampliar os metadados coletados,

analisar o conteúdo dos artigos e desenvolver um processo de anotação e validação humana das evidências.

Fonte e reprodutibilidade

Fonte: PubMed / NCBI E-utilities — https://pubmed.ncbi.nlm.nih.gov/

Consulta: ("Coffee"[MeSH Terms] OR coffee[Title/Abstract]) AND ("Prostatic Neoplasms"[MeSH Terms] OR "prostate cancer"[Title/Abstract])

Coleta UTC: 2026-09-28T11:45:37.295122+00:00

Notebook: notebooks/16_eda_pubmed.ipynb

Dataset: data/pubmed_cafe_cancer_prostata.csv